

Přednáška 8 - Quasi MC & náhodná čísla

Monte-Carlo integrace: $\int_{\Omega} f(x) dx \approx \frac{1}{N} \sum_{i=1}^N f(x_i)$

kde x_1, \dots, x_N iid. Pak

$$\mathbb{P} \left(\left| \frac{1}{N} \sum_{i=1}^N f(x_i) - \int_{\Omega} f(x) dx \right| \leq \sqrt{\frac{\text{var}(f(x))}{\varepsilon \cdot N}} \right) \leq 1 - \varepsilon$$

V praxi máme zatvázané ε , ale (někdy) si můžeme volit

- počet samplingů/pokusů N
- rozdělení, ze kterého vybíráme X

\Rightarrow chyba klesá (\geq pravděp. $1 - \varepsilon$) $\left\{ \begin{array}{l} \text{s rostoucím } N \\ \text{s klesající směr. odchylkou} \\ \text{var}(f(x)) \end{array} \right.$

Na základě těchto pozorování máme několik možností Monte-Carlo:

- importance sampling MC
- quasi MC
- stratified / adaptive / antithetic / MC

Importance sampling

$$\int_{\Omega} f(x) dx = \int_{\Omega} \frac{f(x)}{w(x)} w(x) dx \equiv \int_{\Omega} \tilde{f}(x) dW(x)$$

- kde w je pdf (prob. density function: $w \geq 0, \int_{\Omega} w(x) dx = 1, w = 0$ pro nejdříve konečné body)
- W je cdf (cumulative distribution fun.: $P(X \leq a) = \int_{\Omega} \chi_{X \leq a} dW(x) \equiv \int_{\Omega} \chi_{X \leq a}^{(x)} \cdot w(x) dx$)
 - platí $E(f(X)) = E(\tilde{f}(X^w)) \quad (:= \int_{\Omega} \tilde{f}(x) dW(x))$

Proč to je?

$$\int_{\Omega} f(x) dx = \int_{\Omega} \tilde{f}(x) dW(x) \approx \frac{1}{N} \sum_{i=1}^N \tilde{f}(X_i^w) \quad \dots X_i^w \sim \text{rozdělení } W$$

Stejně jako u MC:

$$P_w \left(\left| \frac{1}{N} \sum_{i=1}^N \tilde{f}(X_i^w) - \int_{\Omega} \tilde{f}(x) dW(x) \right| < \sqrt{\frac{\text{var}(\tilde{f}(X^w))}{N}} \right) = 1 - \varepsilon$$

$$\text{var}_w(\tilde{f}(X)) = E(\tilde{f}(X^w)^2) - \underbrace{E(\tilde{f}(X^w))^2}_{E(f(X))^2} = \int_{\Omega} \left(\frac{f(x)}{w(x)} \right)^2 w(x) dx - (E(f(X)))^2$$

pro porovnání: $\text{var}(f(X)) = \int_{\Omega} f(x)^2 dx - (E(f(X)))^2$

Importance sampling

se používá, pokud máme $w(x)$ t., že

- $\text{var}(\tilde{f}(X^w)) \ll \text{var}(f(X))$
- umíme snadno vyhodnocovat/simulovat $\tilde{f}(X_i^w)$
- umíme snadno generovat $X_1, \dots, X_N \sim$ distribuce W

Importance sampling $\equiv \frac{1}{N} \sum_{i=1}^N \frac{f(X_i^w)}{w(X_i^w)}$

→ oproti normálnímu MC má každá hodnota svojí váhu \equiv importance

Quasi-Monte-Carlo

→ jak v počítači generujeme/simulujeme náhodná čísla?

tzv. pseudo-random generators

- numpy/scipy/MATLAB/R/... standard
- krok 1 → vygenerovat sekvenci náhodných čísel v $(0,1)$ (...uniformní)
- krok 2 → transf. na normální/exponenciální/...
- vygenerovaná čísla nejsou opravdu náhodná, ale zkonstruovaná tak, aby šlo dokázat, že splňují klasické testy náhodnosti

Ale pokud si necháme vygenerovat 10^4 bodů v $(0,1)^2$ tak nedostaneme „rovnoměrné pokrytí“ toho $(0,1)^2$.
(s velkou pravděp.)

Pozorujeme něco jako „lokální clusterování“.

To lze spravit tím, že nepoužijeme „pseudo-random generators“, ale tzv. „quasi-random generators“.

- ty jsou zkonstruovány tak, aby uniformně pokrývaly $(0,1)^d$
- v principu negenerujeme náhodné body, ale deterministické body
- výhoda je, že uniformní pokrytí $(0,1)^d$ již potřebujeme daleko méně než „(uniformní pokrytí $(0,1)^d$)“ my tj. řešíme problém, který jsme měli s „interpolacími kvadraturami“ pro vysoké d .
- „uniformní“ \approx „maximalizujeme počet bodů pro daný rozptyl“

quasi Monte-Carlo $\equiv X_i$ nejsou generovány za použití pseudo-random generátorů, ale za použití quasi-random generátorů.

• místo chyby $O(N^{-1/2})$ lze dokázat $O(\log^d(N) \cdot N^{-1})$

Stratifikované MC \equiv rozdělíme Ω na podoblasti
a aplikujeme MC nezávisle

Adaptivní MC \equiv uděláme stratifikované MC a na podoblastech
s nejvyšší variancí přidáme další samples
můžeme řešit problém pouze tam kde je

Antithetic MC \equiv využijeme symetrii Ω , pokud nějaká je
• když $X \in (0,1)$ pak pro $Y := 1-X$ také $Y \in (0,1)$

• antithetic MC: $\frac{1}{2N} \sum_{i=1}^N f(X_i) + f(Y_i)$

• platí $E(\text{antithetic MC}) = \int_0^1 f dx$
 $\text{var}(\text{---}) = \frac{\text{var}(f(X))}{2n} (1+\rho)$

kde ρ je korelace X a Y

\Rightarrow pokud umíme najít

jednoduchou transformaci $X \rightarrow Y$ která bude mít malou
korelaci, pak „zadarmo“ získáme „dvojnásobek sample
bodů bez větší variance“.

