

Přednáška 14 - Lineární algebraické systémy II

Opáčko Linegebra 1:

Vektorové normy

- $\|\vec{x}\| = \|\vec{x}\|_2 := \sqrt{x_1^2 + \dots + x_n^2}$... obecněji $\|\vec{x}\|_p := \sqrt[p]{|x_1|^p + \dots + |x_n|^p} \quad p \in \mathbb{N}$
 $\|\vec{x}\|_\infty := \max \{|x_1|, \dots, |x_n|\}$

Maticové normy

- $\|A\| = \|A\|_2 := \max_{\vec{v} \in \mathbb{R}^n \setminus \{0\}} \frac{\|A\vec{v}\|_2}{\|\vec{v}\|_2} = \max_{\substack{\|\vec{v}\|_2 = 1 \\ \vec{v} \in \mathbb{R}^n \setminus \{0\}}} \|A\vec{v}\|_2$

- $\|A\|_p := \max_{\vec{v} \in \mathbb{R}^n \setminus \{0\}} \frac{\|A\vec{v}\|_p}{\|\vec{v}\|_p} = \max_{\substack{\|\vec{v}\|_p = 1 \\ \vec{v} \in \mathbb{R}^n \setminus \{0\}}} \|A\vec{v}\|_p$

Vektorová norma nám měří velikost vektoru \leadsto
 \leadsto maticová norma nám měří „velikost matice“ ve smyslu „matice = zobrazení“ \rightarrow „velikost zobrazení \sim jak nejvíce může změnit velikost inputu (relativně).“

- Lze snadno vidět, že:

$$\bullet \|A\vec{v}\|_p \leq \|A\|_p \cdot \|\vec{v}\|_p$$

$$\bullet \|AB\|_p \leq \|A\|_p \cdot \|B\|_p$$

$$\forall p \in \{1, 2, \dots, \infty\}$$

- „velikost matice“ lze měřit i „vektorově“ \rightarrow

\rightarrow tzv. Frobeniova norma $\|A\|_F := \sqrt{a_{11}^2 + a_{12}^2 + \dots + a_{1n}^2 + \dots + a_{n1}^2 + \dots + a_{nn}^2}$

- matice, které zachovávají normu se nazývají unitární

Q je unitární $\Leftrightarrow \forall \vec{v}: \|Q\vec{v}\|_2 = \|\vec{v}\|_2 \Leftrightarrow$ sloupce Q tvoří ortonormální posloupnost

- Opáčko:
- Gaussova eliminace odpovídá okamžité aplikaci LU faktorizace
 - pro obecnou regulární matici A můžeme potřebovat pivotaci
 - i s pivotací může být G.E./LU nestabilní, tj. zaokrouhlovací chyby můžou úplně zkreslit a zkažit vypočtené faktory \hat{L}, \hat{U} .
 - Pro SPD matice (např. kovarianční matice) lze ukázat, že nepotřebujeme pivotaci a zároveň, že G.E./W je stabilní

Že toho přirozeně plynou 2 otázky:

1. Existují stabilní (stabilnější) algoritmy pro řešení $A\vec{x} = \vec{b}$?
2. Jak poznáme/vypočteme podmíněnost konkrétního systému $A\vec{x} = \vec{b}$?

→ opáčko: stabilita = jak konkrétní algoritmus ne/akumuluje zaokrouhlovací chyby

podmíněnost = jak je konkrétní matematický problém citlivý na „malé“ perturbace (změny v datech)

→ stabilní algoritmy jsou nakonec k ničemu pro špatně podmíněné problémy → nestačí se zajímat pouze o stabilitu.

Podmíněnost problému $A\vec{x} = \vec{b}$

Mějme tedy malou perturbaci $A\vec{x} = \vec{b}$:

$$\tilde{A}\tilde{x} = \tilde{b} \quad \text{kde} \quad \frac{\|\tilde{A} - A\|}{\|A\|} \leq \varepsilon_A \quad \& \quad \frac{\|\tilde{b} - b\|}{\|b\|} \leq \varepsilon_b$$

relativní velikosti perturbací $\ll 1$

Pak máme:

$$\tilde{x} - x = A^{-1}(A\tilde{x} - Ax) = A^{-1}(A\tilde{x} - \tilde{A}\tilde{x} + \tilde{A}\tilde{x} - Ax) = A^{-1}((A - \tilde{A})\tilde{x} + \tilde{b} - b)$$

Tudiž:

$$\begin{aligned}
 \|\tilde{x} - x\| &\leq \|A^{-1}\| \cdot \left(\varepsilon_A \|A\| \cdot \|\tilde{x}\| + \varepsilon_b \|b\| \right) \leq \\
 &\leq \|A^{-1}\| \cdot \left(\varepsilon_A \|A\| \cdot \|\tilde{x}\| + \varepsilon_b \|A\| \cdot \|x\| \right) \\
 &\leq \|A^{-1}\| \cdot \|A\| \cdot \left(\varepsilon_A \|\tilde{x} - x + x\| + \varepsilon_b \|x\| \right) \\
 &\leq \|A^{-1}\| \cdot \|A\| \cdot \left(\varepsilon_A \|\tilde{x} - x\| + (\varepsilon_A + \varepsilon_b) \|x\| \right)
 \end{aligned}$$

$$\|\tilde{x} - x\| \cdot (1 - \|A^{-1}\| \cdot \|A\| \cdot \varepsilon_A) \leq \|A^{-1}\| \cdot \|A\| \cdot (\varepsilon_A + \varepsilon_b) \|x\|$$

$$\underbrace{\frac{\|\tilde{x} - x\|}{\|x\|}}_{\text{velikost změny řešení na základě perturbace}} \leq \underbrace{\frac{\|A^{-1}\| \cdot \|A\|}{1 - \|A^{-1}\| \cdot \|A\| \cdot \varepsilon_A}}_{\substack{\uparrow \\ \text{podmíněnost problému } A\vec{x} = \vec{b}}} \cdot \underbrace{(\varepsilon_A + \varepsilon_b)}_{\text{velikost perturbace dat}}$$

Číslo $\|A^{-1}\| \cdot \|A\|$ je tzv. číslo podmíněnosti matice A
 \leadsto klasické značení je $\kappa(A) := \|A\| \cdot \|A^{-1}\|$

Vidíme, že pro omezenou perturbaci dat velikosti ε
 lze matematicky očekávat přesnost řešení
 přibližně řádu $\mathcal{O}(\kappa(A) \cdot \varepsilon) \leadsto$
 \leadsto tj. i pro zcela stabilní alg. máme chyby $\mathcal{O}(\kappa(A) \cdot \varepsilon_{\text{mach}})$

Dovětek k efektivitě LU / G.E.

(≡ sparse)

Viděli jsme, že pro některé aplikace máme A tzv. řídhou, tj. většina prvků A je rovna 0 a ty nenulové prvky jsou „řídhou“, např. aproximace

druhé derivace vedle na matici $A = \frac{1}{h^2} \begin{bmatrix} -2 & 1 & & 0 \\ & 1 & -1 & \\ & & \ddots & \ddots \\ 0 & & & 1 & -2 \end{bmatrix} n \times n$

$n \times n$ z n^2 prvků jich je pouze $3n - 2$ nenulových.

Podobně tomu je pro většinu problémů, které v nějakém smyslu aproximují nebo pracují s derivacemi.

\Rightarrow abychom měli efektivní výpočty, stačí nám pracovat pouze s těmi nenulovými prvky $n \times n$ tzv. „sparse-matrix algorithms“.

Jejich odvozování & implementace je technická a pokročilá, ale jejich používání snadné.

Python demo: sparse vs. dense

storage
&
time

Stabilnější algoritmy

\rightarrow jak nám vznikala nestabilita? Dělení jsme disproporčně velkým nebo malým číslem.

V řeči matic: matice $M^{(k)}$ velmi výrazně měnili normu sloupců & řádků matice $A^{(k-1)}$.

$n \times n$ chtěli bychom navrhnout algoritmy / metody, které převedou A na horní- Δ , ale za použití unitárních maticových transformací, tj. tak, že jejich aplikace neměníme normu.

(nebo ne příliš).

