

# Přednáška 21 - problém nejmenších čtverců

Motivace: Maximum likelihood estimate (MLE)  
předpokládejme, že máme model předpovídající  
jistý jev / fyzikální jev / děj  $\rightarrow$  model v  
závislosti na vstupních datech a kalibraci vrací  
aproximaci / predikci výsledného stavu:

$$\begin{array}{ccc} \vec{x} & \& \vec{\theta} & \rightsquigarrow & \vec{y} \equiv \vec{F}(\vec{x}, \vec{\theta}) \\ \uparrow & & \uparrow & & \uparrow \\ \text{vstupní data} & & \text{parametry modelu} & & \text{predikce modelu} \end{array}$$

Výběr modelu  $\equiv$  problém pro odborníky v dané oblasti.

Volba parametrů ( $\equiv$  kalibrace modelu) na základě dat  $\equiv$  problém matematiky / data-science

Např.: zajímá mě pohyb planet  $\rightarrow$  model je  
pohyb po elipse (Keplerův zákon)  $\rightsquigarrow$  po které?  
 $\rightarrow$  problém nalezení správných parametrů  $\vec{\theta}$ .

- volba modelu (tj. funkce  $\vec{F}(\vec{x}, \vec{\theta})$ ) je u každého problému jiná.

Překvapivě, volba  $\vec{\theta}$  lze analyzovat relativně obecně

Máme dáno: • model, tj. funkci  $f: (x, \vec{\theta}) \mapsto y$

• měření, tj. páry  $(x_i, y_i)$ , t. že v praxi  $x_i$  vede k  $y_i \forall i$

$m >$  měření nikdy není přesné  $\rightarrow$  v hodnotách  $y_i$  máme chyby  
standardně modelujeme jako náhodné veličiny  $\Rightarrow$  i kdybychom  
měli naprosto správný model  $f(\cdot, \cdot)$  a správné parametry  $\vec{\theta}$ , tak

$\delta y_i := f(x_i, \vec{\theta}) - y_i \neq 0$  .... standardně modelujeme jako  
náhodnou veličinu  $\forall i$  }  $\rightarrow$   
 $\rightarrow$  např.:  $\delta y_i \sim N(\mu_i, \sigma_i^2)$

Otázka: jaká volba parametrů  $\vec{\theta}$  činí pozorované chyby  $\delta y_i$   
nejpravděpodobnější?  
(= volba takových parametrů  
se nazývá MLE)

Odpověď: 
$$\mathbb{P}(0 \leq |\delta y_i| \leq \varepsilon) = \varepsilon \cdot \frac{1}{\sigma_i \sqrt{2\pi}} \cdot \exp\left(-\frac{1}{2} \frac{(\delta y_i - \mu_i)^2}{\sigma_i^2}\right)$$
  
$$\& \mathbb{P}(0 \leq |\delta y_i| \leq \varepsilon, i=1, \dots, m) = \left(\varepsilon \cdot \frac{1}{\sigma_i \sqrt{2\pi}}\right)^m \cdot \exp\left(-\frac{1}{2} \sum_{i=1}^m \frac{(\delta y_i - \mu_i)^2}{\sigma_i^2}\right) =$$
  
$$= \left(\varepsilon \cdot \frac{1}{\sigma_i \sqrt{2\pi}}\right)^m \cdot \exp\left(-\frac{1}{2} \cdot \sum_{i=1}^m \left[\frac{1}{\sigma_i} f(x_i, \vec{\theta}) - \frac{y_i - \mu_i}{\sigma_i}\right]^2\right)$$

$\Rightarrow$  čím menší  $\sum_{i=1}^m \left[\frac{1}{\sigma_i} f(x_i, \vec{\theta}) - \frac{y_i - \mu_i}{\sigma_i}\right]^2$  tím větší pravděpodobnost,  
že pro tyto parametry  $\vec{\theta}$  jsme mohli získat tyto měření  $\Rightarrow$

$\vec{\theta}$  vybereme pomocí MLE



$\vec{\theta}$  vezmeme jako argmin  $\left\| \left[ \frac{1}{\sigma_i} f(x_i, \vec{\theta}) - \frac{y_i - \mu_i}{\sigma_i} \right]_{i=1, \dots, m} \right\|^2$

známe  $\rightarrow$  lze spočítat  
$$\min_{\vec{\theta}} \left\| \left[ \frac{1}{\sigma_i} f(x_i, \vec{\theta}) - b_i \right]_{i=1, \dots, m} \right\|^2$$
 --- tzv. problém  
nejmenších čtverců

Ačkoliv  $y_i \sim N(\mu_i, \sigma_i^2)$  není vždy správný předpoklad, na základě CLT (central limit theorem) lze analogicky postupovat i v případě kdy  $y_i$  jsou „pouze“ iid (independent, identically distributed).

Problém nejmenších čtverců (least-squares problem) může

- být
- lineární  $\Leftrightarrow f(x_i, \vec{\theta}) = \vec{a}_i^T \cdot \vec{\theta} + c_i$  pro nějaké  $\vec{a}_i, c_i$
  - nelineární  $\Leftrightarrow$  není lineární

Jak obecně řešíme?  $\rightarrow$  jako v praxi  $\rightarrow$  najdeme „kandidáty“

tj.  $\vec{\theta}_l, l=1,2,\dots$   
pro které

$$\left. \nabla_{\vec{\theta}} \left( \left\| \begin{bmatrix} \frac{1}{\sigma_i} f(x_i, \vec{\theta}) - b_i \end{bmatrix}_{i=1,\dots,m} \right\|^2 \right) \right|_{\vec{\theta}=\vec{\theta}_l} \stackrel{(*)}{=} 0$$

- pro lineární LS  $\rightarrow$  lze „explicitně“ spočítat
- pro nelineární LS  $\rightarrow$  musíme použít numerické metody k aproximaci takových bodů.

Některé numerické metody ale s  
vůbec nepracují a uplatňují jiné postupy.

Lineární LS:

$$f(x_i, \vec{\theta}) = \vec{a}_i^T \cdot \vec{\theta} + c_i \Rightarrow \begin{bmatrix} f(x_1, \vec{\theta}) \\ \vdots \\ f(x_m, \vec{\theta}) \end{bmatrix} = \begin{bmatrix} \vec{a}_1^T \cdot \vec{\theta} + c_1 \\ \vdots \\ \vec{a}_m^T \cdot \vec{\theta} + c_m \end{bmatrix} = \begin{matrix} \uparrow & \uparrow \\ \begin{bmatrix} -\vec{a}_1- \\ -\vec{a}_2- \\ \vdots \\ -\vec{a}_m- \end{bmatrix} & \begin{bmatrix} c_1 \\ \vdots \\ c_m \end{bmatrix} \end{matrix} \cdot \vec{\theta} + \vec{c}$$

$$\Rightarrow \left\| \begin{bmatrix} \frac{1}{\sigma_i} f(x_i, \vec{\theta}) - b_i \end{bmatrix}_{i=1,\dots,m} \right\|^2 = \left\| \underbrace{\frac{1}{\sigma_i} A \cdot \vec{\theta}}_{=: A} + \underbrace{\vec{c} - \vec{b}}_{=: \vec{b}} \right\|^2$$

$\rightarrow$  přeznačíme:

$\Rightarrow$  lineární LS  $\sim \min_{\vec{\theta} \in \mathbb{R}^n} \|A\vec{\theta} - \vec{b}\|^2$

kde  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$

$m > n \equiv$  počet měření  $\&$   $n \equiv$  počet parametrů

$\Rightarrow m > n$  nebo dokonce  $m \gg n$

$\Rightarrow A$  je obdélníková

Pozorování  $\|A\vec{\theta} - \vec{b}\|^2 \geq 0 \ \forall \vec{\theta} \Rightarrow$  hledáme  $\vec{\theta}$   
t., že  $A\vec{\theta} = \vec{b} \rightsquigarrow$  řešení lin. soust. rovnic s  
obdélníkovou maticí.

Lze převést na systém s čtvercovou? ty už „umíme“

Lemma:  $\nabla_{\vec{\theta}} (\|\vec{b} - A\vec{\theta}\|^2) = 2 \cdot A^T (A\vec{\theta} - \vec{b})$

(lze přímo vypočítat  $\rightarrow$  „jednoduché“ cviko z analýzy)

$\Rightarrow \left[ \nabla_{\vec{\theta}} (\|\vec{b} - A\vec{\theta}\|^2) = 0 \Leftrightarrow \boxed{A^T A \vec{\theta} = A^T \vec{b}} \right]$   
tzn. systém normálových rovnic

$A^T A \sim n \begin{matrix} \boxed{m} \\ \boxed{n} \end{matrix} \sim \begin{matrix} \boxed{n} \\ \boxed{n} \end{matrix}$  ☺

ale sestavit  $A^T A$  vyžaduje násobení matic (drahé) ☹️

